

基于深度学习的商品评价情感分析与研究^{*}

刘智鹏¹ 何中市¹ 何伟东² 张 航¹

(1. 重庆大学计算机学院 重庆 400044)(2. 重庆邮电大学计算机科学与技术学院 重庆 400065)

摘 要 移动互联网助推的电子商务时代使得商品评价空前繁荣,论文提出一种基于深度学习的改进型模型来分析评价数据的情感。首先通过分词与综合停用词表等预处理数据集,然后使用 Skip-gram 模型训练出数据集中每个词的词向量,并使用自扩充情感词典对评价语句情感极性进行量化,量化的情感正负值与词向量形成融合矩阵输入,并通过分流规则设计进行差异网络输入,选择 CNN 或 RNN 完成抽象特征提取,即 Shunt-C&RNN 商品评价分类模型(改进型深度学习)。与传统机器学习 SVM 相比,改进型深度学习准确率大幅提升 6.6%,较单一深度学习提高了近 1.5%。

关键词 深度学习;自然语言处理;词向量;卷积神经网络;循环神经网络;分流器;情感

中图分类号 TP391 **DOI:**10.3969/j.issn.1672-9722.2018.05.015

Commodity Evaluation Analysis and Research Based on Deep Learning

LIU Zhipeng¹ HE Zhongshi¹ HE Weidong² ZHANG Hang¹

(1. School of Computer Science, Chongqing University, Chongqing 400044)

(2. School of Computer Science and Technology, Chongqing University of Posts and Telecommunications, Chongqing 400065)

Abstract This paper proposes an improved deep learning model for commodity evaluation sentiment analysis. Firstly, this paper uses stop words and tokenizer to pretreatment the data, then Skip-gram model is used to generate word vectors. Secondly, an autogenerated sentiment lexicon is used to quantify the sentiment polarity of words in commodity reviews and integrate this information into the model input matrix. Lastly, this paper counts the differences between the network input through the distribution rules of designed and chose RNN or CNN for feature extraction. Above all is the Shunt-C&RNN commodity reviews sentiment classification model (improved deep learning approach). Compared with the traditional machine learning SVM and the single deep learning method the proposed method has improved the precision by 6.6% and 1.5% respectively.

Key Words deep learning, natural language processing, word embedding, CNN, RNN, shunt, sentiment analysis

Class Number TP391

1 引言

移动互联网将电子商务推向了一个空前繁荣的时代,用户在移动终端的购物便利操作早已成为这个时代的习惯,伴随而来的是大量的商品评价语句的产生、沉淀、积累。这些短文本基本处于 300 字以下,高频区间在 30 字~70 字之间,涵盖了大量对于商品的情感倾注。随着海量的情感性商品评价的到来,产品评价正受到用户的成倍关注,产品

评价情感分析正成为一个愈加重要的自然语言处理研究方向。

情感分析是指分析文字语言中所表达或隐藏的情绪状态,目前,对此领域主要的分析研究方法基本上还是传统的机器学习算法和统计学相关方法,例如支持向量机(SVM)、信息熵(Entropy)、条件随机场(CRF)、TF-IDF(Term Frequency-Inverse Document Frequency)等。传统机器学习对于本身文本的特征提取依赖严重,整个过程人为因素干扰

^{*} 收稿日期:2017年11月19日,修回日期:2017年12月23日

基金项目:国家交通部科技项目(编号:2011318740240);重庆市研究生科研创新项目(编号:CYS16031)资助。

作者简介:刘智鹏,男,硕士研究生,研究方向:自然语言处理、数据挖掘。何中市,男,博士,教授,博士生导师,研究方向:自然语言处理、图像识别、机器学习。何伟东,男,研究方向:自然语言处理。张航,男,博士研究生,研究方向:机器学习、自然语言处理。

大,李婷婷等^[1]曾尝试通过对文本数据的人工特征构建,并利用机器学习算法进行情感分类,但分类效果严重依赖人为特征选择。Hinton 等^[2]2006 年提出了深度信念网络(DBN)的学习方法,采用逐层贪婪的思路^[3]改善传统梯度下降所带来隐藏层训练效果差的问题。Kim^[4]在 2014 年将图像领域发展迅速的卷积神经网络引入到了自然语言处理领域,通过文本向量化处理类似图像矩阵输入卷积神经网络学习处理获得了较好的分类效果。

为了解决传统机器学习应用中所产生的文本特征提取选择主观性难题,同时进一步改善目前深度学习技术在图像领域应用广泛,却在自然语言处理相关领域缺乏实践应用的尴尬处境,提升产品评价情感判断的准确性,本文提出了一种基于深度学习中卷积神经网络(CNN)与递归神经网络(RNN),并结合改善的文本向量化输入、设计分流器(Shunt)优化输入的分流型卷积神经网络与递归神经网络融合型分类模型(Shunt-C&RNN)。

2 研究现状

2.1 深度学习与自然语言处理

深度学习通过一系列深层的学习网络,以仿生学、脑科学的角度模拟,进而对图像、语音、文字进行分析。伴随深度学习的快速发展,自然语言处理(natural language processing, NLP)也获得了许多关注。从 2003 年加拿大蒙特利尔大学教授 Bengio 等^[6]提出用 embedding 将词映射进入矢量表示空间。到 2008 年 NEC Labs American 的研究员 Collobert 和 Weston^[7]开始最早的深度学习与 NLP 结合的研究工作,采用 embedding 和多层一维卷积的结构进行词性标注、分块、命名实体等。再到 2012 年 Schwenk 等^[8]采用 BLEU(bilingual evaluation understudy, BLEU)评分机制,运用在统计机器翻译任务中,提高了近 2 个百分点。此外,深度学习相关技术与算法还在语义消歧^[9]、情感分析^[10-11]等自然语言处理任务中取得不俗成绩,甚至超越了很多当时的传统方法。

2.2 卷积神经网络与递归神经网络

卷积神经网络最早是在 1998 年由 leCun 等提出,主要用于手写字符的图像识别,且都是小图片的识别。直到 2012 年 Krizhevsky^[12]使用了较深的卷积神经网络模型,并在 ImageNet 大规模视觉识别挑战赛中将图片分类错误率降低了近 50% 而名声大噪。而到 2016 年著名的围棋人机大战以 4:1 大胜李世石的 AlphaGo 即采用了卷积神经网络,使其

更加备受重视。目前卷积神经网络应用已经十分广泛,在图像、语音、文字方面都成为了十分流行且重要的深度学习算法。

循环神经网络与卷积神经网络同属于深度学习中影响面较大的神经网络算法,但在结构和发展上完全不同。Mikolov T 等^[13]在 2010 年使用循环神经网络处理上下文语言信息。随后为解决梯度膨胀与遗失, Morin F^[14]提出了长短时记忆(Long Short-Term Memory, LSTM)型循环神经网络。2015 年,Chen 等^[15]将循环神经网络中的 LSTM 型神经网络进行中文分词类应用,发挥了其上下文关系学习的优势,取得了很好的分词效果。整体而言,循环神经网络在上下文关系连接方面具有更加明显的优势,同时和卷积神经网络形成互为优势的配合。

2.3 word2vec 工具与词向量(word embedding)

谷歌公司在 2013 年正式发布了 Word2vec 开源工具。此工具采用了人工神经网络方面理论,可将具体文本词汇转换为实数向量。步骤基本是先通过训练文本语料库构建词汇表,再根据连续词袋模型模型或 Skip-gram 模型训练得到每个词的词向量^[16]。在向量空间中词向量是面向语义的,所以向量即多维空间,从夹角或距离也可反映词语语义上的相似,这就使得文字处理更加数字化和形象化。

而其中的神经网络概率语言模型在十余年的发展中,先出现了例如由 Bengio 等^[17]提出的神经网络概率语言基础模型 NNLM(Neural network language model);而后伴随结构优化,提出了经典的 CBOW 模型与 Skip-gram 模型^[17]。

其中 Skip-gram 模型在自然语言处理中十分实用,其模型如图 1 所示。




图1 Skip-gram 模型结构图

Skip-gram 模型的训练目标就是使得下式的值最大:

$$\frac{1}{M} \sum_{a=1}^M \sum_{b=1}^w \log w_{a+b|w_a}$$

其中, w 是窗口的大小,在 Skip-gram 模型中就是指 n-Skip-gram 中的 n 的大小, M 是训练文本的大

小。在 word2vec 中,使用的是 w-Skip-gram-bi-grams。在其训练过程当中,需要语料足够丰富全面,其次需要尽可能多地反映词语间的关系,这就使得完整语句纳入其中十分重要。

3 基于深度学习的情感分类模型

本文提出的基于深度学习的电子商务产品评价模型的建立与设计主要分为5个步骤,整体模型流程如图2所示。

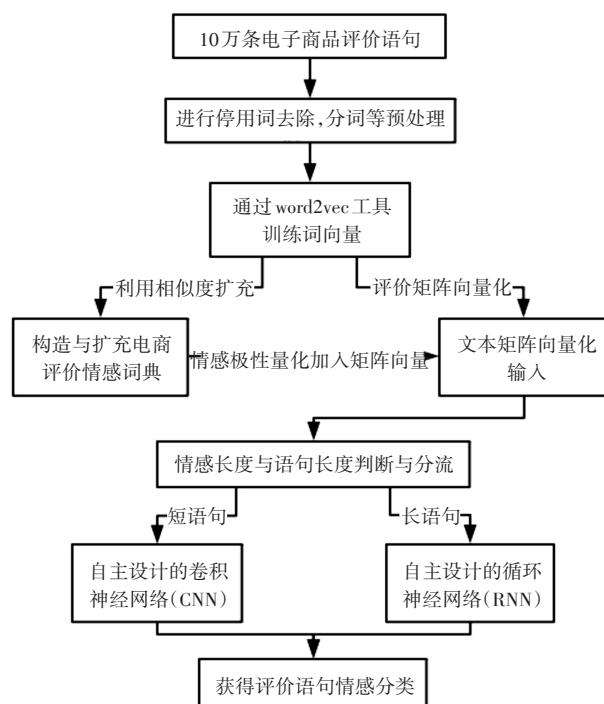


图2 本文情感分类模型处理流程

1) 运用 word2vec 工具,根据 Skip-gram 模型进行训练,将每条评论语句转化为词向量。

2) 运用相似度计算,搜索爬取海量电商评价语料中相近的网络评价情感词,并根据相似程度,自动标注情感倾向,构建并扩充电子商务评价情感词典。

3) 设计出具有较好收敛速度,对短文本语句具有良好分类效果的卷积神经网络(CNN)模型。

4) 设计出基于 LSTM 且运用合理的循环神经网络(RNN)模型。

5) 设计判断输入 CNN 还是 RNN 的分流器(Shunt),判断语句是输入 CNN 还是 RNN 最合适,同时二维正负情感值加入词向量中作为附加特征,一并输入。

3.1 构造电商产品评价的情感词典

情感词典在词性的情感极性上作为分类标准十分重要,目前中文情感词典常见的有知网的 HowNet 词典、《学生褒贬义词典》、清华大学李军提

供的褒贬义词典、台湾大学的“NTUSD”简体中文情感词典等。本文综合了常见的情感词典,将所有情感词去重细化筛选后,正向情感词共计 8405 个,负向情感词共计 3116 个。

但从传统情感词典中不难发现,许多针对互联网环境下的电子商务产品评价情感词汇十分缺乏。为了进一步优化和扩充情感词典的正负向情感词,本文爬取了 10 万条在线真实产品评价语料,并从中进行分词等预处理后开始进行词典扩充。整体构造与扩充词典步骤如下。

1) 通过 word2vec 工具构造 10 万条评论语料中每个词汇的 200 维词向量。

2) 通过对海量语料的词频统计,梳理出前 7000 个高频词汇,并标注 7000 高频词汇的正负向极性(若无情感倾向为中性)。

依据 7000 高频词汇中标注的正负向情感词的词向量,对 10 万条评论中词汇词向量进行相似度计算,选取最靠近的前五个词汇,标注相同情感极性,如图 3。

```

1 喜欢
2 [('适合', 0.6571873426437378),
3  ('高兴', 0.6473183631896973),
4  ('开心', 0.5970351099967957),
5  ('好看', 0.5849385857582092),
6  ('炫', 0.557742714881897)]
7
8 很快
9 [('挺快', 0.8381614685058594),
10 ('超快', 0.8198286890983582),
11 ('够快', 0.7513157725334167),
12 ('快', 0.744819164276123),
13 ('飞快', 0.738010048866272)]
14
15 流畅
16 [('顺畅', 0.8612161874771118),
17 ('畅快', 0.7205485105514526),
18 ('流畅性', 0.6419352293014526),
19 ('顺手', 0.6121967434883118),
20 ('稳定', 0.6019488573074341)]
21
22 好看
23 [('漂亮', 0.826569139957428),
24 ('很漂亮', 0.7081484794616699),
25 ('炫酷', 0.7071567177772522),
26 ('炫', 0.6998022794723511),
27 ('薄', 0.6606646180152893)]
  
```

图3 相似词的词向量矢量距离处理示意图

通过以上方法,本文将 885 个具有明确正负情感的高频词汇与其最相似的 3690 个新标注情感词,共计 4575 个情感新词全部扩充进入情感词典,并带有明确情感倾向。同时这 4575 个词均来自最真实的海量在线评价语料中,进一步完善和更新了当前网络情感用语的丰富度,对于后续情感词典匹配、语句情感量化,都提供了更为精准的支撑。至此关于电商产品评价情感词典构建完成。

3.2 构建基于词向量与情感极值的矩阵输入

卷积神经网络过去常用于图像处理,在输入方面选取图像矩阵输入较为常见。而在本文中,将把文本数据处理为词向量(word Embedding),首先将文本进行停用词去除,并对每个评论语句进行分词

处理,同时通过 word2vec 将每个词词向量求出,如图 4 所示,每个句子最多可分解为 n 个词,同时每个词转为 k 维的词向量,即一句评论文本将成为 $n \times k$ 的二维矩阵。本文将词向量 k 设为 200 维,同时为控制矩阵的稀疏度,将文本评价语料控制在最多见的 64 字以内,即 64×200 的矩阵表示一句评论文本,少于 64 字的评价语料进行补零处理。

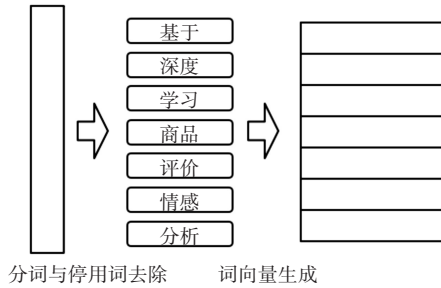


图4 相似词的词向量矢量距离处理示意图

除图 5 本身语料转化的词向量矩阵“ $\{X_1, X_2, X_3, \dots, X_i\}$ ”外,本文对每句评价语料进行了扩充词典的正负情感词匹配,从而量化评价语料的情感正负极性,并将量化后的情感极性值正向(positive)方面+1,负向(negative)方面-1,为防止因训练不足导致的分类精度降低,将情感极值向量进行拉普拉斯平滑,如下式所示。

$$P_{\lambda}(X^{(j)} = a_{jk} | Y = C_n) = \frac{\sum_{i=1}^M I x_i^{(j)} = a_{jk}, y_i = C_n + \lambda}{\sum_{i=1}^M I y_i = C_n + S_j \lambda}$$

$$P_{\lambda}(Y = C_n) = \frac{\sum_{i=1}^M I y_i = c_n + \lambda}{M + N \lambda}$$

其中 a_{jk} 代表第 j 个特征的第 k 个选择, S_j 代表第 j 个特征的个数,而 N 代表种类的个数。




图5 模型输入向量的处理示意图

最终形成一个如图 5 所示的全新输入向量:

$$K = (P, W, N)$$

其中 P 为正向情感量化向量, P_a 为第 a 个词的 12 维 $\{P_{a1}, P_{a2}, \dots, P_{a12}\}$ 正向(positive)情感量化向量,且增加至 X_{a1} 之前,其中 a_{ij} 为一句评价语料的第 i 个词的情感量化值; W 为通过 Skip-gram 得到的词向

量, N 为负向情感量化向量, N_a 为第 a 个词的 12 维 $\{N_{a1}, N_{a2}, \dots, N_{a12}\}$ 负向(negative)情感量化向量。

共计 24 维的情感极值增加项是试验测试后针对 200 维词向量矩阵较好的影响占比的选择。

3.3 构建 Shunt-C&RNN 模型

为了使得深度学习的多种方法更加精细化运用于文本情感分析,在利用了卷积神经网络(CNN)的优秀特征学习能力,同时构建循环神经网络(RNN)利用其时间轴索取前后关联内容学习的优势,分别处理产品评价在语料情感与文字长度差异化的语料。在对产品评价语料进行两种深度学习算法调用处理的辨识时,充分考虑了每个评价的情感词数量、情感词极性、整体语料文本长度、文本所体现的情感占比(情感词数/文本总词数)等因素。

3.3.1 设计分流器

本文对于文本的分流处理采用了字段长度和情感极性两个重要判断依据,字段长度主要体现一段评论的前后文关联性,同时在每句评价语料中情感的丰富程度,情感极性量化可对其进行判断。通过多次实验测试,本文在分流器规则设计方面,选择将 30 字以上且情感丰富度高的语料输入 RNN 网络,其余则输入 CNN 网络进行处理。

3.3.2 构建 CNN 网络模型

本文采用的多层卷积神经网络模型(CNN),整个模型由 3 层卷积层、1 层池化层、1 层 Flatten 层、1 层全连接层及 Softmax 层构成,结构如图 6 所示。




图6 CNN模型结构结构图

卷积核 $\omega \in R^{h \times k}$ 是对窗口大小为 h 的 k 维词向量进行卷积操作,输出特征为

$$X_i = f(\omega \times C_{i:i+h-1} + b)$$

其中 X_i 为特征, $C_{i:i+h-1}$ 为输入的文本向量, f 为激活函数,较常见的如 sigmoid 函数、tanh 函数、ReLU 函数等,本文考虑了整流线性函数对基于梯度方法的优化属性与训练收敛速度,故采用了 ReLU 函数作为激活函数:

$$f(x) = \max(0, x)$$

本文每层卷积层由 128 个 3×3 的卷积核来学习并提取文本情感特征。卷积核 ω 对输入向量 $K = (P, W, N)$ 进行卷积,即可得到一张特征图:

$$X = [x_1, x_2, \dots, x_{n-h+1}], X \in R^{n-h+1}$$

随后的池化层采用 max-pooling 层提取特征集中最有代表性的特征,然后通过全连接层来完成正负情感的映射,最后用 Softmax 层进行情感分类。Softmax 对于多分类与二分类问题均适用,在本文仅利用 Softmax 进行正负向情感二分类,如下式所示。

$$g(p) = \text{softmax}(W)$$

其中 p 为每次合并后父节点的向量, W 为类标签权重向量。在情感分类训练单句时,令 g 服从二项分布,Softmax 层输出的分类可以视做计算条件概率 $g(k) = p(k|x_i, x_j)$, 其中 $k=0$ 或 1 , $g(0)$ 表示文本倾向负向情感的概率, $g(1)$ 表示文本倾向正向情感的概率。

在本文的 CNN 模型设计与构建中,全连接层引入了 Dropout 策略以防止过度拟合,经实验调参测试,将 Dropout 丢弃率设为 0.5。同时窗口批量输入大小 batch 设置为 8,且在调参中将学习速率 lr 设为 0.01,衰减速率 $decay$ 设为 $1e^{-5}$,将会获得较好的整体效果。

3.3.3 构建 RNN 网络模型

本文构建的循环神经网络模型(RNN),整个模型由 2 层 LSTM 层及 Softmax 层构成,每层 LSTM 一共有 512 个神经元,结构如图 7 所示,且每一层都有一个叫 cell state 的结构用来传递整句序列的信息,其表达式为

$$C_t = f_t \times C_{t-1} + i_t \times \tilde{A}_t$$

其中 C_t 表示 cell state 在第 t 个神经元处的值, f_t 表示第 t 个神经元中被丢弃的信息,由第 t 层神经元的输入和第 $t-1$ 层的神经元经过线性运算并使用 sigmoid 函数得到, i_t 表示第 t 个神经元中什么值需要更新,计算方法与 f_t 相同, \tilde{A}_t 表示创建一个新的 cell state 候选值,计算方法与 f_t 相似,只是最后使用 tanh 函数得到 \tilde{A}_t 。




图7 RNN模型结构图

在本文构造的 RNN 网络结构中,每一个神经元的输出为

$$h_t = O_t \times \tanh(C_t)$$

其中 h_t 表示第 t 个神经元的输出, O_t 表示第 t 个神经元需要保留的信息,计算方式与 f_t 值相同。第二层 LSTM 与第一层 LSTM 一致。最后将这 512 个神经元全连接实现正负情感的映射,最后使用 Softmax 函数(同 CNN 中的 Softmax 函数相同)进行情感分类。

在 RNN 模型的设计与构建中,每一层 LSTM 都引入了 Dropout 策略,随机放弃 20% 的参数以防止过拟合,并且减少参数使计算更快。同时窗口批量大小 batch 设置为 16,优化算法为 RMSProp,并设置其参数学习速率 lr 为 0.001,模糊因子 epsilon 为 $1e^{-8}$,最终得到效果较好的 RNN 模型。

4 实验及结果分析

4.1 实验环境

本文所有实验均在如表 1 所示环境中完成。

表1 实验环境与配置

实验环境	环境配置
操作系统	Windows10
CPU	Intel Core i3-3240 3.4GHz
GPU	GTX1060
内存	8G
深度学习框架	tensorflow 1.3.0-gpu
程序语言	Python 3.5
分词工具	Jieba 0.38
词向量训练工具	word2vec(gensim2.3.0)

4.2 实验数据集准备与预处理

实验数据集来自京东商城(www.jd.com)3C 产品的用户好评与差评数据,未选取情感倾向较弱的中评数据。该数据集中一共 140000 条评论样本,其中为使得 word2vec 训练的词向量更加准确,其使用了所有语料。其中选取了 40000 条评论样本,正负向情感各 20000 条,作为所有分类模型实验的数据样本,并按照数量的 8:2 进行训练集与测试集划分。

数据集选择和划分后,还有数据预处理步骤:

- 1) 调整获取语料的格式与字符。同时调整统一的编码,去掉不相关符号、空格、特殊字符等。
- 2) 停用词去除。使用丰富的 3 类停用词表进行去重综合,再进行停用词去除。
- 3) 分词操作。使用分词工具包进行分词,使每个评论语句词语精简,便于后续训练词向量。
- 4) 训练词向量。使用 google 已经开源的 gensim2.3.0 工具包,调用 word2vec 方法。同时为得到

较高质量的词向量,除本身 40000 条训练集与测试集语料加入之外,另加入了 100000 条同出处评论语料参与训练。

4.3 实验评价指标

本文实验评估指标主要采用有准确率(*precision*)、召回率(*recall*)、*F1* 值。准确率体现了算法模型获得正确结果的能力,召回率则反映了算法模型获得相关结果的能力,而 *F1* 值则综合考虑了前两个指标的平衡性,它们之间联系紧密,计算公式为

$$precision = \frac{\text{模型自动且正确分类到该类的文本数}}{\text{模型自动分类到该类的文本数}} \times 100\%$$

$$recall = \frac{\text{模型自动且正确分类到该类的文本数}}{\text{人工分类到该类的文本数}} \times 100\%$$

$$F1 = \frac{2 \times precision \times recall}{precision + recall} \times 100\%$$

4.4 实验步骤

具体实验步骤如下。

1) 构造与扩充电商评价情感词典,通过词向量的相似度计算,在原有词汇中扩充获得 4~5 倍电商与网络环境下流行的正负向情感词汇。

2) 计算每条评价的情感极值。通过构造和扩充的情感词典进行每条评价的情感词语匹配,从而计算情感量化极值。

3) 构造 CNN 或 RNN 的数据输入向量。将情感极值的正负向情感值分别作为本身词向量的前后各 12 维的扩展填充向量,形成新的输入向量。

4) 分流选择性输入 CNN 或 RNN 处理。根据每个评价的内容长度与输入向量的情感极值,判断输入 CNN 模型还是 RNN 模型处理。

5) 性能评估。输出分类结果,根据结果计算实验评价指标体系中的数值。

4.5 实验对比与结果分析

本文实验主要采用了“传统机器学习方法”、“深度学习方法”与“改进的深度学习分流式方法”进行实验对比,结果均采用了十折交叉验证。

4.5.1 对比实验

在对于本文分类算法的输入上均采取 200 维词向量(word embedding),本文分类算法对比主要是传统机器学习方法 SVM,常用的深度学习方法 CNN 与 RNN,还有改进型的分流式深度输入深度学习 Shunt-C&RNN,具体如下。

SVM 模型: 本文使用 word2vec 训练词向量,每个词为 3 维向量,每个词顺次排列组成一个行向量,通过训练寻找这两类行向量的支持向量构造

SVM 分类器。

CNN 模型: 同样使用 word2vec 训练词向量,将词向量与 24 维增加的情感向量合并后,输入 CNN 网络训练,构造良好分类效果的 CNN 网络。

RNN 模型: 与 CNN 模型输入的数据完全相同,只是网络变为基于 LSTM 的 RNN 网络。

Shunt-C&RNN 模型: 本文将评论语料从字数长度和感情量化值大小进行分流,选择性输入 CNN 模型或 RNN 模型进行处理。

4.5.2 实验结果

四组算法模型实验结果如表 2 所示。实验结果均经过多次交叉验证,多次实验取平均,具有较好的稳定性与可信度。

表 2 实验结果

分类模型	准确率/%	召回率/%	<i>F1</i> 值/%
SVM 模型	86.07	80.63	83.26
CNN 模型	91.72	92.15	91.94
RNN 模型	91.25	94.15	92.68
Shunt-C&RNN 模型	92.68	93.15	92.91

4.5.3 实验分析

根据实验数据表 2 与图 8、图 9 所示,深度学习方法 CNN 模型与 RNN 模型相比于传统的机器学习方法 SVM 模型,从准确率、召回率到 *F1* 值都有较多提升,主要源于本身特征提取与学习的方式上智能化与数据化,深度学习依靠仿生脑科学与大数据,这体现了很大的优势。




图 8 模型 CNN 与 RNN 的 ACC 曲线图




图 9 模型 CNN 与 RNN 的 LOSS 曲线图

在短文本处理方面,构建的CNN模型具有更快的收敛速度,同时准确率方面高于RNN模型近0.5%,而RNN模型则具有更强的上下文关联,在返回相关结果能力上更强,召回率高出CNN模型达2%。

而本文提出的结合了两种网络模型特性优势所构建的分流型深度学习网络模型即Shunt-C&RNN算法,既发挥了深度学习优于传统机器学习方法的分类精度,又进一步将RNN模型上下文关联和CNN高效收敛相结合,取得了对比实验中最好的效果。

5 结语

本文提出了一种基于深度学习的改进型模型Shunt-C&RNN,获得了对比与传统机器学习方法SVM及深度学习方法CNN模型与RNN模型更好的文本情感识别性能。主要贡献有以下三点:

1)通过词向量相似度计算,扩充与构建了电商评价情感词典,有效补充了当前的流行网络情感词。

2)将大量数据训练后的词向量及量化情感值融合,形成了模型更具情感特征的新的输入向量。

3)构造与设计了CNN与RNN模型,并进行了有效的融合,恰当地利用了各自对短文本的处理优势。

由于深度学习应用在自然语言处理方面相比于图像的发展还较为缓慢,在许多应用场景和参数调整细节上还有待验证,下一步将更深入地探究不同网络对于情感语料处理的模型参数设置相关联系。

参考文献

- [1] 李婷婷,姬东鸿. 基于SVM和CRF多特征组合的微博情感分析[J]. 计算机应用研究, 2015, 32(4): 978-981.
LI Tingting, JI Donghong. Sentiment analysis of micro-blog based on SVM and CRF using various combinations of features[J]. Application Research of Computers, 2015, 32(4): 978-981.
- [2] Hinton GE, Salakhutdinov RR. Reducing the dimensionality of data with neural networks[J]. Science, 2006, 313(5786): 504-507.
- [3] Hinton GE, Osindero S, Teh Y. A fast learning algorithm for deep belief nets[J]. Neural Computation, 2006, 18(7): 1527-1554.
- [4] Kim Y. Convolutional neural networks for sentence classification[C]//Proceedings of Conference on Empirical Methods Natural Language Processing. Association for Computational Linguistics, 2014: 1746-1751.
- [5] 张军阳,王慧丽,郭阳,等. 深度学习相关研究综述[J]. 计算机应用研究(网络优先出版), 2018, 35(7). <http://www.aocmag.com/article/02-2018-07-067.html>.
- [6] Bengio Y, Vincent P, Janvin C. A neural probabilistic language model[J]. Journal of Machine Learning Research, 2003, 3(6): 1137-1155.
- [7] Collobert R, Weston J, Karlen M, Kavukcuoglu K, Kuksa P. Natural language processing (almost) from scratch[J]. Journal of Machine Learning Research, 2011, 12(1): 2493-2537.
- [8] Schwenk H, Rousseau A, Attik M. Large, pruned or continuous space language models on a GPU for statistical machine translation[C]//NaacL-hlt Workshop: Will We Ever Really Replace the N-gram Model on the Future of Language Modeling for Hlt. 2012: 11-19.
- [9] Socher R, Huval B, Manning CD, Ng AY. Semantic compositionality through recursively-matrix-vector spaces[C]//Joint Conference on Empirical Methods in Natural Language Processing & Computational Natural Language Learning. 2012: 1201-1211.
- [10] Le Q, Mikolov T. Distributed representations of sentences and documents[C]//International Conference on International Conference on Machine Learning, 2014, 4: II-1188.
- [11] Chen Y. Convolutional Neural Network for Sentence Classification[D]. Canada: University of Waterloo, 2015: 2-9.
- [12] 10 Breakthrough Technologies 2013[EB/OL]. MIT Technology Review, 2013-04-23(5). <https://www.technology-review.com/lists/technologies/2013/>.
- [13] Mikolov T, Karafiát M, Burget L. Recurrent Neural Network Based Language Model[C]//Proceedings of the 11th Annual Conference of the International Speech Communication Association, 2010: 1045-1048.
- [14] F, Morin, Y Bengio. Hierarchical probabilistic neural network language model[C]//The 8th International Conference on Artificial Intelligence and Statistics (AISTATS), 2005.
- [15] CHEN X C, QIU X, ZHU C, LIU R, HUANG X. Long short-term Memory neural networks for chinese word segmentation[C]//Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing, 2015: 1385-1394.
- [16] 陈柯宇. 酒店领域文本情感分类研究[D]. 重庆: 重庆大学, 2017: 20-21.
CHEN Keyu. Research on Text Sentiment Classification of Hotel Field[D]. Chongqing: Chongqing university, 2017: 20-21.
- [17] Bengio Y, Ducharme R, Vincent P. A neural probabilistic language model[J]. Journal of Machine Learning Research, 2003, 3(7): 1137-1155.