

基于双向循环神经网络的评价对象抽取研究

陈 鹏, 徐 冰, 杨沐昀, 李 生

(哈尔滨工业大学 计算机科学与技术学院, 哈尔滨 150001)

摘 要: 评价对象抽取的研究难点在于如何精确地表示大范围的上下文信息。本文针对微博观点句, 采用了基于双向循环神经网络(BRNN)的方法来抽取评价对象并对评价对象的情感倾向进行判定。BRNN的隐藏层对上下文进行了抽象, 如果经过良好地训练, 就能在循环处理句子时有效地表示远距离的有序上下文信息, 而无需对上下文窗口长度进行限定。本文选择了词、词性、依存句法树以及产品词典等特征构建了BRNN模型。通过实验发现, 上述4种特征组合获得了最优实验结果, 通过与CRF模型的对比, 本文提出的方法在相互覆盖模式下 F 值比CRF模型高出0.61%, 验证了本文方法的有效性。本文方法在COAE2015任务3的资源受限评测任务中, 获得了最好结果。

关键词: 情感分析; 评价对象抽取; 双向循环神经网络模型; 条件随机场模型

中图分类号: TP391

文献标志码: A

文章编号: 2095-2163(2017)01-0071-05

Bidirectional Recurrent Neural Network for opinion target extraction

CHEN Peng, XU Bing, YANG Muyun, LI Sheng

(School of Computer Science and Technology, Harbin Institute of Technology, Harbin 150001, China)

Abstract: The challenge of opinion target extraction is how to represent wide-range context accurately. The paper focused on opinion sentences from microblog and employed a method based on Bidirectional Recurrent Neural Network(BRNN) to extract opinion targets and judge their emotion tendency. The hidden layer of BRNN can abstract context. If the model is trained well, it can represent wide-range, ordered context effectively without the limitation of the length of the context window. The paper chooses the word, the part of speech, the dependency parsing and the product dictionary as features to build the BRNN model. The results of experiment show that the combination of four features mentioned above achieves the best performance. Compared with CRF model, the F value of overlap mode increased by 0.61% using the method proposed in this paper, which validates the method is effective. The method proposed in this paper gets the best result in COAE2015 task3 with limited resources.

Keywords: sentiment analysis; opinion target extraction; Bidirectional Recurrent Neural Network model; conditional random field model

0 引 言

随着电子商务的兴起以及微博微信的流行, 人们经常会在这些平台上发表评论, 其中蕴含着大量有用的信息。从海量的微博中识别出观点句, 其后挖掘抽取评价对象并进行情感分析, 不仅能够帮助其他用户了解评价对象的细节信息, 而且对于企业在展开市场分析与产品升级时更能提供有的放矢的决策参考建议。

研究可知, 评价对象抽取通常可延展为2方面的任务, 具体如下:

1) 评价对象识别。从大量微博句子中识别出评论句, 然

后从中抽取被评论的对象。需要抽取的评价对象包括产品名与属性名, 其中产品名主要是指产品品牌与型号, 属性是指产品的组成构件(例如屏幕对于手机)或者是产品的特征功能(例如操作手感)。

2) 评价对象的情感倾向性判定。判断被抽取出的评价对象在评论句中的情感倾向性。例如, “三星 GalaxyS3 拍照很不错的!”这句话就是一条评论句, 评价对象的产品名为“三星 GalaxyS3”, 属性名为“拍照”, 其情感倾向性是褒义。

基于此, 本文则研究提出了一种基于BRNN的方法来识别微博观点句中的评价对象, 尝试了不同特征组合, 观察各类组合对抽取结果的影响, 并将BRNN与传统RNN方法和CRF方法进行了比较研究, 实验结果表明本文提出的方法在相互覆盖模式下优于其它2种方法。

1 相关工作

评价对象抽取可以被形式化为序列标注任务, 目前序列标注方法中CRF模型因其要明显优于其它模型的研究效果而得到广泛采用。文献[1]使用CRF抽取评论者, 文献[2]

基金项目: 国家自然科学基金(61402134); 中央高校基本科研业务费专项资金资助(HIT.NSRIF.2015068)。

作者简介: 陈 鹏(1991-), 男, 硕士研究生, 主要研究方向: 自然语言理解、文本情感分析; 徐 冰(1975-), 女, 博士, 副教授, 主要研究方向: 自然语言理解、文本情感分析。

收稿日期: 2016-12-28

使用 CRF 抽取被评价的产品属性。这些抽取任务的实现都是直接将标记注明在词上,而 semiCRF 则改进了马尔可夫假设,允许在短语级别上进行序列标注。进一步地,文献[3]即基于 semiCRF 抽取观点表达。同时,已有分析表明 CRF 模型的设计局限就是其性能将高度依赖于特征的选取以及特征模板的设计。综合以上研究内容都是有监督学习方法,一般需要大量人工标注的训练语料,费时费力,当领域发生改变时,模型性能将会出现明显下降。评价对象抽取的另一研究开发类别就是无监督方法,过程中不需要标注语料,可直接从句子中获取潜在的评价对象。文献[4]同时抽取评价对象与观点词,如果评价对象 T_1 和评价对象 T_2 具有较强的联系,而且 T_2 和观点词 O 具有较强的关系,那么可以推断出 T_1 和 O 也具有强关系。文献[5]根据评价对象和观点词之间的双向传播获得评价对象词集和观点词集合。其输入是一些未标注语料与一个观点种子集,然后对语料进行依存句法分析,根据分析结果扩展评价对象和观点词。文献[6]基于词对齐方法获得评价对象和观点词之间的相关度,设计采用的是 IBM-3 模型,和一般用于机器翻译的词对齐方法不同,其限制名词或名词词组只能和形容词或动词对齐,其余词只能和自己对齐。

近年来,深度学习方法应用于 NLP 领域已然吸引了研究学界的普遍重视与关注。神经网络试图将词表示成低维稠密的词向量,使得意义相近的词在向量空间中距离相近,这为神经网络应用于自然语言处理提供了可行思路。文献[7]通过 RNN 来构建语言模型,其中的隐藏层能够表示历史,且不受窗口大小限制。鉴于 RNN 的隐藏层只能表示历史而对当前词之后的信息却未给出任何提示,因此文献[7]把当前词之后指定窗口大小内的词整合到当前输入,即用 n-hot 代替原来的 1-hot 向量作为输入,该方法受限于窗口的大小,在窗口之外的信息则将做忽略处理。文献[8]提出了 BRNN 模型,并将其隐藏层划分为前向隐藏层和后向隐藏层,实现中前向隐藏层将和 RNN 的隐藏层一样记录历史,而后向隐藏层却用于设计记录将来的信息,这样就使得将来的信息不会受限于窗口大小。文献[9]基于深度双向循环网络进行观点挖掘。

2 方法描述

2.1 循环神经网络

和一般的前馈神经网络相比,循环神经网络至少有一条循环突触连接。本文研究选用的是 Elman 结构,将其按时间展开后的结构如图 1 所示。




图 1 循环神经网络结构

Elman 结构是由位于底部的输入层,位于中间的隐藏层和位于顶部的输出层组成。前一时刻的隐藏层与此时的隐藏

层之间也存在连接突触,这使得隐藏层具备了记录历史输入的潜力。每一层是由一系列神经元组成,层与层之间通过突触进行全连接。假设输入 x_t 表示维度为 N (N 表示词表规模)的向量,通过 $1 - \text{Of} - N$ 向量表示;输出 y_t 也是个向量,维度大小和标注个数 M 相等,表示当前输入的标注结果的概率分布;状态 s_t 记录了句子的历史(规定 $s_0 = 0$),其维度 L 由外部设定;输入层到隐藏层的突触权重为 U ($L \times N$ 的矩阵),前一时刻隐藏层到此时的隐藏层的突触权重为 V ($L \times L$ 的矩阵),隐藏层到输出层之间的突触权重为 W ($M \times L$ 的矩阵)。则 RNN 的计算过程如式(1)所示。

$$\begin{aligned} s_t &= f(Ux_t + Vs_{t-1} + b) \\ y_t &= g(Ws_t + c) \end{aligned} \quad (1)$$

$$\text{其中 } f(z) = \frac{1}{1 + e^{-z}}, g(z_k) = \frac{e^{z_k}}{\sum_m e^{z_m}}$$

本文基于 RNN 对句子进行序列标注,根据标注结果抽取评价对象。具体来说,在对句子进行分词后,使用 RNN 从前到后循环地进行计算:在时刻 t 时,模型已计算得到前一时刻的状态 s_{t-1} ,而 x_t 通过当前词使用 $1 - \text{Of} - N$ 编码得到,然后根据式(1)分别计算得到 s_t 和 y_t 。其中, y_t 是 x_t 的标注结果的概率分布,取最大概率者作为 x_t 的标注。由于本文采用的标注集数量较小,标注转移的影响不大,所以本文直接将各个时刻的最佳标注结果连接起来作为句子整体的标注序列。最后,根据标注结果抽取评价对象,例如假设标注结果中存在 3 个词,其标注结果依次为“F-B, F-I, F-I”,则将这 3 个词连接起来,作为该句评价对象的评价属性。

本文采用的目标函数如式(2)所示:

$$L(\phi) = \sum_{s \in S} \sum_{x_i \in s} \sum_m t_i^{(m)} \ln y_i^{(m)} \quad (2)$$

其中, S 表示语料集合, $s = \{x_1, \dots, x_t, \dots, x_T\}$ 是集合中的一个句子, $t_i^{(m)}$ 表示输入 x_i 的第 m 种标记的教师值(如果当前输入 x_i 人工标注为第 m 种标记,则 $t_i^{(m)}$ 的值为 1,否则为 0)。 $y_i^{(m)}$ 表示网络计算得出的第 m 种标记的归一化概率, ϕ 为待训练参数 $\phi = \{U, V, W\}$ 。本文采用 BPTT (back propagation through time) 算法来最大化式(2)。

2.2 双向循环神经网络

前述网络结构是单向循环神经网络,因为隐藏层只记录了历史。这对于序列标注任务来说是不够的,因为当前输入的标注结果不仅和上文有关,和下文也有关系。为了充分利用 RNN 的隐藏层能记录任意长度历史的优点,本文采用如图 2 所示的 BRNN 结构来增加下文信息。




图 2 双向循环神经网络结构

Fig. 2 The structure of Bidirectional Recurrent Neural Network

可以看到, s_1 为前向隐藏层, 而且和 RNN 中的隐藏层一样, 记录了历史。相对地, s_2 为后向隐藏层, 对应表示着下文的信息。BRNN 的运算过程如式 (3) 所示:

$$\begin{aligned}\vec{s}_t &= f(\vec{U}x_t + \vec{V}\vec{s}_{t-1} + \vec{b}) \\ \overleftarrow{s}_t &= f(\overleftarrow{U}x_t + \overleftarrow{V}\overleftarrow{s}_{t+1} + \overleftarrow{b}) \\ y_t &= g(\vec{W}\vec{h}_t + \overleftarrow{W}\overleftarrow{h}_t + c)\end{aligned}\quad (3)$$

其中, 激活函数 f 和 g 的定义与式 (2) 一样。在这个式子中, $\vec{s}_t, \overleftarrow{s}_t$ 分别代表前向隐藏层和后向隐藏层 ($\vec{s}_0 = \overleftarrow{s}_T = 0$), 每个隐藏层有着各自一套权重矩阵。可以看出, 时刻 t 的后向隐藏层是由当前输入以及时刻 $t+1$ 时的后向隐藏层计算得出的, 而这与前向隐藏层的计算恰呈相反顺序。使用 BRNN 对句子进行序列标注的流程和 RNN 基本一致。要想训练 BRNN, 其目标函数和训练 RNN 时一样, 并以句子为单位, 采用 BPTT 算法进行训练^[10]。其中, 后向隐藏层的局域梯度的计算顺序也与前向隐藏层成相反设计, 后向隐藏层是从时刻 1 开始向后计算的。

2.3 特征选择

本文为序列中的每个词选取了如下这些语言学特征和先验知识, 分别是: 1) 词性; 2) 依存句法树特征; 3) 产品名领域词典。

加入词性特征是考虑到评价对象基本都是以名词形式出现, 如果一个词是名词, 那么就有可能成为评价对象。加入依存句法树特征是因为诸如“amod”及“nsubj”等依存关系常常能够准确地连接评价对象和观点词^[11], 该特征包含 2 个元素: 支配词与依存关系。最后, 考虑到主要面对的是汽车和电子等领域的语料, 而且训练语料只包括了少量几种品牌的评论数据, 加入产品名领域词典特征则旨在基于神经网络能够通过该先验知识提高标注产品名时的性能。获得每个特征的向量表示之后, 将它们按照固定的顺序连接起来作为 BRNN 的输入。

3 实验

3.1 数据介绍

本文的测试数据来自于 COAE2015 任务 3, 共有 133 201 条微博语句, 其中包含了大量的干扰句。对测试语料进行分词与词性标注, 然后对其中的名词生成词频统计后, 即会发现测试语料绝大多数都分布在汽车、手机与其它电子产品三个领域。本文的训练语料规模为 9 071 句。

3.2 处理流程

实验的处理流程如图 3 所示。

在此, 将针对各主要设计步骤给出详细阐释解析如下。

1) 规范化训练语料。首先使用 NLP/ICTCLAS2015 分词系统 (<http://ictclas.nlpir.org/>) 对训练语料进行分词。为了提高分词器对产品名词的准确度, 本文收集了汽车和手机等领域的品牌名, 并将其加入到分词器的用户词典中。然后对分词后的训练语料展开语言学特征抽取处理, 包括词性标注和依存句法树分析 (<http://nlp.stanford.edu/software/nnldep.shtml>), 将分析结果作为训练语料的重要特征。同时, 根据词是否出现在产品名词典中添加领域特征。而后再对训练语料进行人工序列标注。

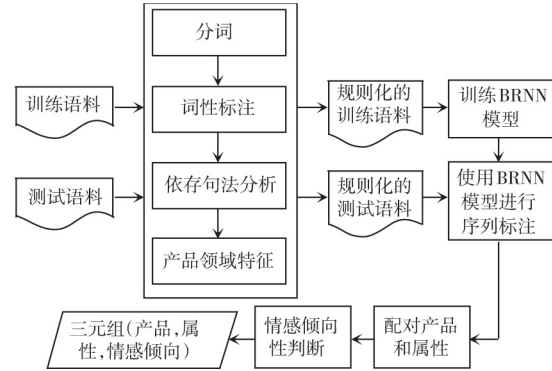


图3 实验处理流程

Fig. 3 Experiment process flow

2) 模型训练与评价对象识别。使用训练集和开发集数据训练 BRNN 模型, 最大化目标函数式 (2), 训练方法使用 BPTT 算法。其中训练集数据用于优化突触权值, 开发集用于评估 BRNN 的性能, 以此判定是否需要终止训练。本文对训练语料中的词设置了一个最小词频阈值, 小于阈值的纯数字表示为 <NUMBER>, 小于阈值的纯字母表示为 <ENGLISH>, 小于阈值的由数字、字母、破折号、下划线等构成的字符串规格化为 <ENGLISH_NUMBER>, 小于阈值的其它词则表示为 <UNKNOWN_WORD>。超过阈值的词由其本身来实现表示, 但英文全部规格化为小写形式。本文将最小词频阈值设置为 5。BRNN 训练完成后, 对测试语料进行序列标注。

3) 生成答案。首先配对产品名称和产品属性, 以产品属性为中心配对最近的产品名; 然后判定评价对象的情感倾向, 若微博标注出产品属性, 则在产品属性的上下文中寻找情感词, 否则就在产品名的上下文中控制寻找。根据情感词典判定其情感倾向, 若情感词之前存在否定词, 还需要反转情感倾向。

3.3 评价指标

文本采用精确率、召回率和 $F1$ 测度值作为评价指标, 定义:

$a = |\{ \text{评价对象} \mid \text{该评价对象出现在答案中, 且预测中存在评价对象与之匹配} \}|$

$b = |\{ \text{评价对象} \mid \text{该评价对象出现在预测中, 但答案中没有对应评价对象与之匹配} \}|$

$c = |\{ \text{评价对象} \mid \text{该评价对象出现在答案中, 但预测中没有对应评价对象与之匹配} \}|$

其中, $| \{ s \} |$ 表示集合 s 的元素个数。匹配包括精确匹配和相互覆盖两种, 精确匹配是指答案和预测完全一致才可称作匹配成功, 相互覆盖是指只要答案和预测存在交集即已获得匹配成功。如果同时考虑情感倾向性的话, 就需要将每种评价对象继续细分, 原理一致。则精确率 p 、召回率 r 和 $F1$ 测度值计算如式 (4) 所示:

$$p = \frac{a}{a+b}, \quad r = \frac{a}{a+c}, \quad F1 = \frac{2 \times p \times r}{p+r} \quad (4)$$

3.4 不同特征组合与模型对性能的影响

为了考察不同输入特征对 BRNN 的影响, 本文从输入只有词本身开始, 逐步添加额外特征, 探讨分析这些特征对抽取结果的影响。除此之外, 为了观察在相同输入的情况下, 不同模型抽取结果的影响, 本文还选择了 RNN 模型 (隐藏层规模

= 100) 与 CRF 模型作为对比进行重点研究。实验结果如表 1 所示,其中不带特征的模型表示输入只有词本身,fea1 表示特

征集{词性},fea2 表示特征集{词性,依存句法关系},fea3 表示{词性,依存句法关系,产品名特征}。

表 1 不同模型与特征的实验结果

Tab. 1 Result of different model and features

匹配方式	模型+特征	T - p	T - r	T - F1	F - p	F - r	F - F1	macro - F1	micro - F1
精确匹配	BRNN	0.654 9	0.415 1	0.508 2	0.579 9	0.542 2	0.560 4	0.539 2	0.542 9
	BRNN+fea1	0.665 6	0.413 1	0.509 8	0.598 8	0.549 0	0.572 8	0.546 4	0.551 7
	BRNN+fea2	0.633 7	0.444 6	0.522 6	0.607 5	0.510 1	0.554 5	0.539 7	0.543 2
	BRNN+fea3	0.631 9	0.511 6	0.565 4	0.606 7	0.514 4	0.556 7	0.561 2	0.559 9
	RNN	0.686 7	0.406 0	0.510 3	0.559 1	0.458 3	0.503 7	0.510 3	0.506 0
	RNN+fea3	0.658 6	0.443 4	0.530 0	0.564 1	0.503 7	0.532 2	0.533 7	0.531 4
	CRF	0.689 2	0.476 1	0.563 1	0.655 6	0.509 9	0.573 6	0.568 9	0.5698
	CRF+fea1	0.688 1	0.494 8	0.576 6	0.645 5	0.521 0	0.576 6	0.576 6	0.576 3
	CRF+fea2	0.695 4	0.494 8	0.578 2	0.655 0	0.515 3	0.576 8	0.577 9	0.577 4
	CRF+fea3	0.689 5	0.518 3	0.591 8	0.651 1	0.515 3	0.575 3	0.583 6	0.581 3
相互覆盖	BRNN	0.801 4	0.507 8	0.621 6	0.715 0	0.659 6	0.686 2	0.659 6	0.664 7
	BRNN+fea1	0.810 0	0.501 6	0.619 5	0.730 6	0.660 0	0.693 5	0.662 3	0.668 9
	BRNN+fea2	0.778 0	0.545 2	0.641 1	0.750 0	0.625 0	0.681 8	0.662 7	0.667 4
	BRNN+fea3	0.758 9	0.613 9	0.678 7	0.747 3	0.626 0	0.681 3	0.680 1	0.680 3
	RNN	0.797 8	0.471 9	0.593 0	0.684 0	0.554 7	0.612 6	0.606 4	0.605 9
	RNN+fea3	0.775 7	0.522 5	0.624 4	0.688 8	0.608 1	0.646 0	0.638 4	0.638 6
	CRF	0.791 8	0.547 2	0.647 2	0.769 2	0.597 6	0.672 6	0.660 4	0.663 4
	CRF+fea1	0.780 6	0.562 7	0.654 0	0.761 4	0.614 9	0.680 3	0.667 7	0.670 8
	CRF+fea2	0.782 2	0.558 6	0.651 7	0.770 9	0.606 7	0.679 0	0.665 8	0.669 1
	CRF+fea3	0.779 5	0.588 4	0.670 6	0.766 6	0.606 6	0.677 3	0.674 0	0.674 8

首先,相比于只输入词本身,加入词性特征在完全匹配模式下抽取性能提升较明显。再加入依存句法树特征后,产品名的 $F1$ 值提升较大,但产品属性的 $F1$ 值却有所下降,这主要是因为特征的增加使得产品属性的召回率下降较大,而产品属性的精确率上升较小。继续加入产品名特征后,明显提升了产品名的 $F1$ 值,而产品属性的 $F1$ 值变化不大,这表明加入产品名特征后的确能有效提升产品名的抽取性能。对于宏平均 $F1$ 和微平均 $F1$,在加入这些特征后,BRNN 的抽取性能都有所提升,在相互覆盖匹配模式下,使用 fea3 特征集的模型的宏平均 $F1$ 比不加额外特征的模型提升了 2.05%,微平均 $F1$ 提升了 1.56%。比较 BRNN 与 RNN 可以看到,在相同特征下,BRNN 的性能将显著优于 RNN,这是因为 BRNN 的隐藏层同时包含了上下文的信息,而 RNN 只有上文信息,说明了加入后向隐藏层能够提升抽取性能。最后比较 BRNN 与 CRF,在相同特征下,BRNN 抽取产品属性的 $F1$ 值都要优于 CRF 模型,由于抽取产品属性还需要考虑上下文更加复杂的特质,这即说明了 BRNN 更准确地学习到了产品属性抽取的规律。从整体来看,BRNN 在完全匹配模式下总体性能略逊于 CRF,但在相互覆盖模式下却比 CRF 要好,这也说明 BRNN 更擅长

发现关键词,将关键词扩展成抽取的结果还需要展开更多的处理。

3.5 评价对象抽取整体测试

该节设计研发、并展示了使用 COAE2015 的测试数据,经过产品名与产品属性抽取,产品名和产品属性配对以及情感倾向性判定的整体流程处理后结果。隐藏层规模设置为 50,并选取词性、依存句法关系与产品名特征构建 BRNN 模型。然后按照 3.2 节所述步骤进行后期处理。最终 COAE2015 任务 3 的评测结果如表 2 所示。表中系统 MI&TLAB_r1 是基于 BRNN,系统 MI&TLAB_r2 是基于 CRF,Best 是指评测最优成绩,Medium 是指评测成绩中位数。

可以看出在资源受限的评测中,BRNN 在许多指标上接近甚至达到了最优值。值得注意的是,虽然 BRNN 在整体性能上略逊于 CRF,但 BRNN 在各匹配模式上的召回率都要优于 CRF,这主要是因为 CRF 是根据指定大小的窗口内计算一系列的特征加权来进行标注的,这即使得如果评价对象和观点词相距较远且没有直接的依存句法关系时,CRF 将无法准确地识别出评价对象,而 BRNN 通过前向和后向隐藏层记录上下文则有效避免了窗口大小的限制。

表 2 资源受限的评价对象抽取的宏观与微观评测结果

Tab. 2 Results on macro and micro of opinion target extraction with limited resources

匹配模式	系统	micro - p	micro - r	micro - F1	macro - p	macro - r	macro - F1
all 覆盖	MI&TLAB_r1	0.086 7	0.244 2	0.128 0	0.058 2	0.161 0	0.085 5
	MI&TLAB_r2	0.092 2	0.222 4	0.130 3	0.061 6	0.143 8	0.086 2
	Best	0.092 2	0.244 2	0.130 3	0.061 6	0.197 4	0.086 2
	Medium	0.054 3	0.184 4	0.073 1	0.044 3	0.137 7	0.056 0
all 精确	MI&TLAB_r1	0.063 6	0.179 1	0.093 9	0.043 4	0.117 9	0.063 5
	MI&TLAB_r2	0.068 3	0.164 7	0.096 6	0.047 6	0.109 3	0.066 3
	Best	0.068 3	0.179 1	0.096 6	0.047 6	0.161 8	0.066 3
	Medium	0.039 0	0.138 9	0.052 8	0.032 0	0.104 4	0.040 7

4 结束语

本文针对 COAE2015 评测任务 3,提出了基于 BRNN 的方法抽取评价对象。相比于传统的 RNN 模型,BRNN 的最大优点是同时考虑了上下文,而且不受窗口大小的限制。本文尝试了不同的特征组合作为输入的性能变化。同时本文还将 BRNN 与 CRF 模型抽取结果进行了比较,实验结果表明在不需要大量特征堆砌的前提下,BRNN 模型在召回率方面优于 CRF 模型,在精确率上比 CRF 略低,所以如何进一步提高 BRNN 的精确率是今后需要改进的方向。

参考文献:

- [1] CHOI Y, CARDIE C, RILOFF E, et al. Identifying sources of opinions with conditional random fields and extraction patterns[C]// HLT '05 Proceedings of the conference on Human Language Technology and Empirical Methods in Natural Language Processing. Vancouver, British Columbia, Canada: ACM, 2005: 355-362.
- [2] XU Bing, ZHAO Tiejun, ZHENG Dequan, et al. Product features mining based on Conditional Random Fields model [C]// International Conference on Machine Learning & Cybernetics. Qingdao, China: IEEE, 2010, 6: 3353-3357.
- [3] YANG B, CARDIE C. Extracting opinion expressions with semi-Markov Conditional Random Fields [C]//Joint Conference on Empirical Methods in Natural Language Processing & Computational Natural Language Learning. Jeju Island, Korea: ACM, 2012: 1335-1345.

- [4] LIU Kang, XU Liheng, ZHAO Jun. Extracting opinion targets and opinion words from online reviews with graph co-ranking [J]. Proceedings of the 52nd Annual Meeting of the ACL. Baltimore, Maryland, USA: ACL, 2014: 314-324.
- [5] QIU Guang, LIU Bing, BU Jiajun, et al. Opinion word expansion and target extraction through double propagation [J]. Computational Linguistics, 2011, 37(1): 9-27.
- [6] LIU Kang, XU Liheng, ZHAO Jun. Opinion target extraction using word-based translation model [C]// Proceedings of the 2012 Joint Conference on EMNLP and Computational Natural Language Learning. Jeju Island, Korea: ACM, 2012: 1346-1356.
- [7] MIKOLOV T, ZWEIG G. Context dependent recurrent neural network language model [C]// Spoken Language Technology Workshop (SLT). Miami, FL: IEEE, 2012: 234-239.
- [8] SCHUSTER M, PALIWAL K K. Bidirectional recurrent neural networks [J]. IEEE Transactions on Signal Processing, 1997, 45(11): 2673-2681.
- [9] IRSOY O, CARDIE C. Opinion mining with deep recurrent neural networks [C]// Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. Doha, Qatar: ACL, 2014: 720-728.
- [10] JAEGER H. A tutorial on training recurrent neural networks, covering BPPT, RTRL, EKF and the "echo state network" approach [M]. fifth revision. Germany: Fraunhofer Institute for Autonomous Intelligent Systems, 2013.
- [11] JAKOB N, GUREVYCH I. Extracting opinion targets in a single- and cross-domain setting with conditional random fields [C]// Conference on Empirical Methods in Natural Language Processing. Cambridge, Massachusetts: ACM, 2010: 1035-1045.

(上接第 70 页)

来的棋局影响,评价函数在基本对局的策略上开展棋局的评估与决策,并实现棋局的状态更新与计算等操作。但是本项目仍然存在亟需改进的内容方面,例如可以研究提出搜索函数来进行多层棋局的估计与估值以提高机器的评价准确性,尽量避免水平效应的发生。也可以使用蒙特卡罗方法设计推进棋局模拟并开发生成合适的决策。

参考文献:

- [1] 中国人工智能学会机器博弈专业委员会. 爱恩斯坦棋项目规则 [EB/OL]. [2015-08-14]. <http://www.caaigames.net/>.

- [2] 周文敏,李淑琴. 爱恩斯坦棋静态攻防策略的研究[J]. 电脑知识与技术, 2014, 10(5): 1027-1031.
- [3] 李占宇,李淑琴,顾磊,等. 爱恩斯坦棋算法设计与分析[J]. 信息技术与信息化, 2014(1): 107-110.
- [4] 王小春. PC 游戏编程(人机博弈) [M]. 重庆: 重庆大学出版社, 2002: 1-119.
- [5] 王静文,吴晓艺. 全国大学生计算机博弈大赛培训教程[M]. 北京: 清华大学出版社, 2013: 1-161.
- [6] PRATA S. C++ Primer Plus[M]. 张海龙,袁国忠,译. 北京: 人民邮电出版社, 2015: 1-838.